

图神经网络导论

图结构学习

授课教师：周晟

浙江大学 软件学院

2022.12



课程内容

- ① 研究背景
- ② 基于优化的图结构学习
 - LDS
 - Pro-GNN
- ③ 基于图结构学习的图神经网络
 - AGCN
 - GRCN
 - PTDNet
 - Geom-GCN
 - IDGL
- ④ 基于生成模型的图结构学习
- ⑤ 无监督的图结构学习



上节课回顾



计算机网络



社交网络



交通网络



神经元网络



卫星网络



上节课回顾

困难与挑战

- ① 传统图神经网络难以充分建模富信息网络特点
- ② 不同类型富信息网络需要设计不同的图神经网络结构

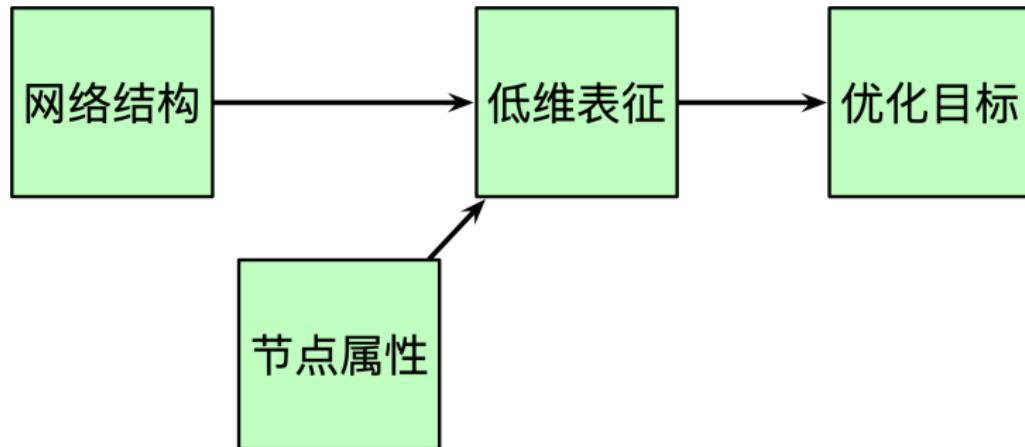
常见的富信息图神经网络

- ① 有向图
- ② 异构图
- ③ 动态图

研究背景

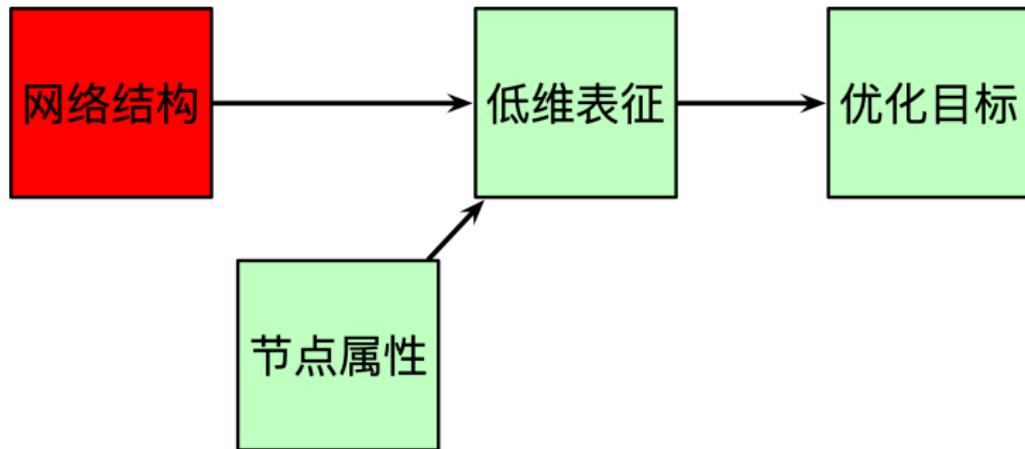
图神经网络的原理

通过将节点的**信息**沿着**网络结构**传递 (Message Passing)，捕获节点间的关系和节点的特征，学习更好的图 (节点，边，图) 表征。



图神经网络基本框架

研究背景



网络结构受损下的图神经网络

问题与挑战

实际场景中，网络结构往往面临受损或缺失的问题，使得依赖网络结构信息的图神经网络效果严重下降。

图结构缺失问题

- ① 数据天然的稀疏性（社交网络关注量有限）
- ② 数据采集、存储过程中丢失
- ③ 人为隐藏关系（犯罪）
- ④ 数据集本身没有关系型结构



图结构冗余问题

- ① 数据采集、存储过程中错误
- ② 电商网络中，刷单行为（诈骗高发）
- ③ 人为注入，“浑水摸鱼”



图结构学习的意义

图结构学习对于图神经网络的理论和应用均有重要意义：

图结构方面：

- ① 理解数据间的真实关系（因果）
- ② 预测图结构演化趋势
- ③ 发掘数据中异常关系

图神经网络方面：

- ① 更好的消息传递路径
- ② 迭代升级的图神经网络框架
- ③ 鲁棒图神经网络



图数据的思考

我们希望生成什么样的图？（和真实世界的图尽量接近/相似）

- ① 二八定律 (Pareto principle, 也被称为 80/20 法则、关键少数法则、八二法则、帕累托法则)，是指约仅有 20% 的变因操纵着 80% 的局面。
- ② 网络中节点的度的分布，并不是均匀的。
- ③ ...



同质性 (homophily)

同质性 (homophily)

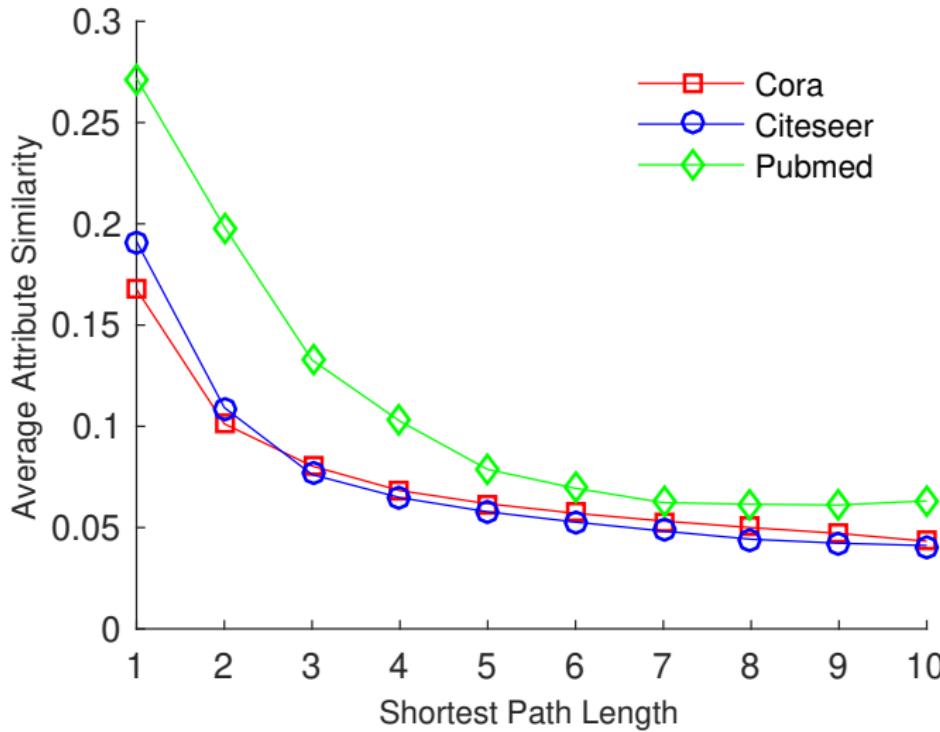
同质性 (homophily)，指一个图网络中相邻节点相似的程度。在节点分类任务中，同质性通常被定义为相邻节点属于同一类别的概率。

可以证明，在同质性为 1 的极端情况下，GNN 可以达到100%的准确率。因此，**如何产生更具有同质性的图结构**是图结构学习中值得思考的问题。



特征平滑性 (Smoothness)

真实数据集上节点属性和拓扑结构相关性分析



图统计量

除了节点级的局部特征，大规模真实图数据往往具备特殊的宏观性质。

常用如下四种统计量来描述一个图的全局性质：

- ① 度分布, Degree distribution: $P(k)$
- ② 聚类系数, Clustering coefficient: C
- ③ 连通区域, Connected components: s
- ④ 路径长度, Path length: h



图统计量

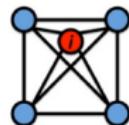
- 度分布, Degree distribution $P(k)$ 是指: 度为 K 的节点数量的分布, $N_k =$ 度为 k 的节点数量,

$$P(k) = N_k/N$$

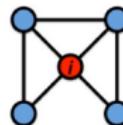
- 聚类系数, Clustering coefficient

$$C_i = \frac{2e_i}{k_i(k_i - 1)}$$

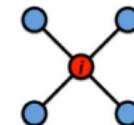
- e_i 是 i 节点的邻居中互相连边的数量
- k_i 是 i 节点的度



$$C_i = 1$$



$$C_i = 1/2$$



$$C_i = 0$$

$$C_i \in [0,1]$$

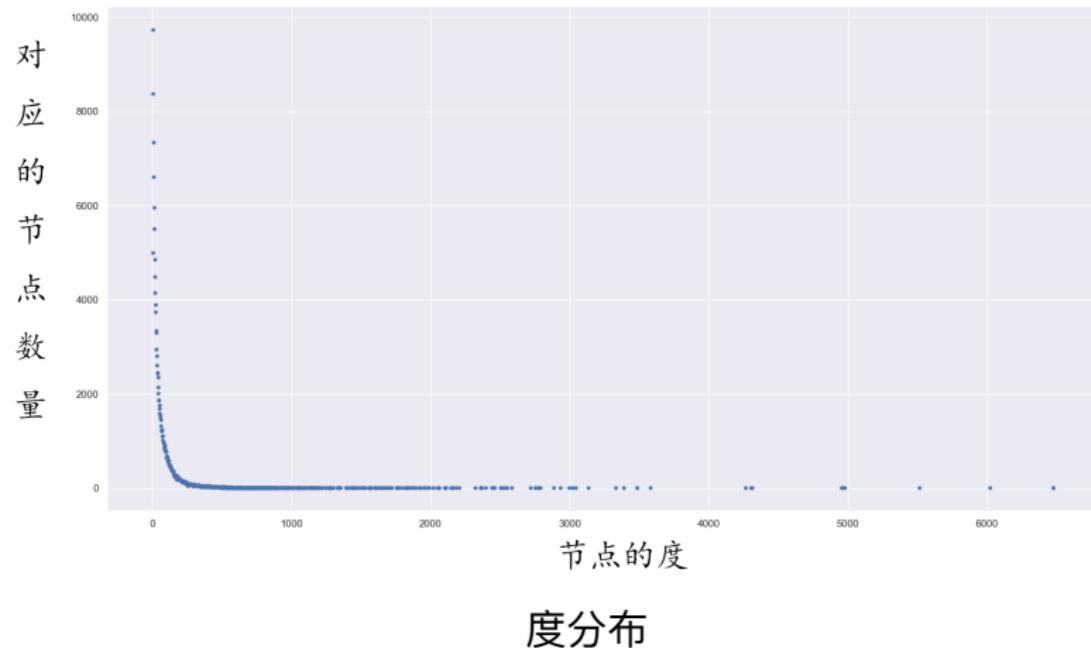


图统计量

- 连通区域，Connected components，指图中联通区域按大小排序，其不同大小连通区域数量的分布
- 路径长度，Path length，指图中所有存在的最短路径的长度分布
- 以 Twitter 的社交网络图数据集为例，该数据集的邻接矩阵大小为 157575×157575

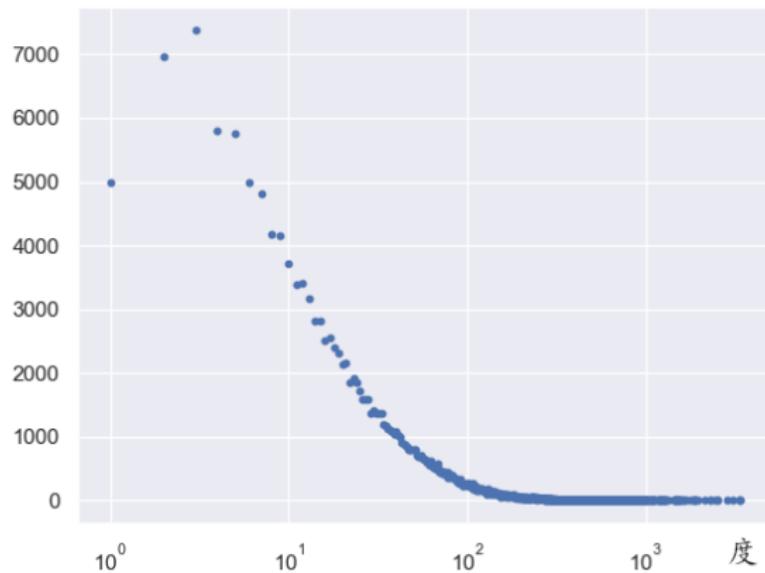


图统计量-以 Twitter 数据集为例



图统计量-以 Twitter 数据集为例

点的数量



横轴指数化的度分布

随机图的度分布

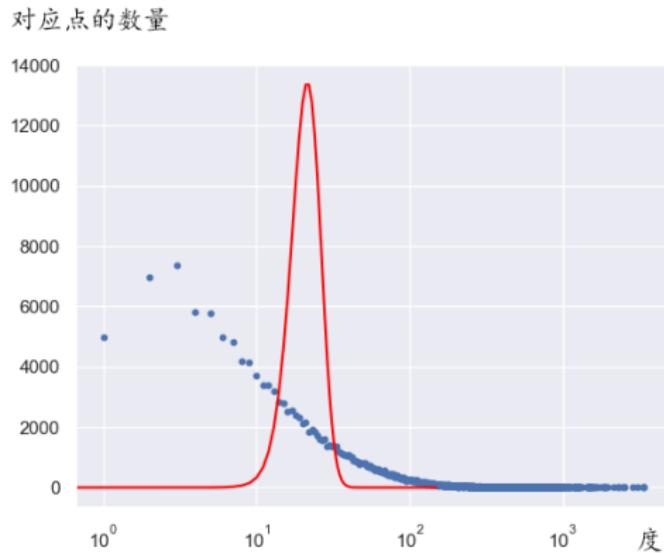
$$p(k) = \binom{N-1}{K} P^k (1-P)^{N-1-k}$$

- 一个点的度为 k 的概率 (有 k 个点与之相连), 等价于除它本身之外的 $N-1$ 个点选 k 个和它相连, 剩下 $N-1-k$ 和它不连的概率。 P 是两点之间存在一条边的概率,
 $P = \frac{E}{N*N}$ 。典型二项分布。
- 好的图结构学习结果应保留图的这种天然特性



随机图的度分布

- 以 Twitter 数据集为例，其中共有 157575 点 3530653 边，把真实分布和随机分布（红色）画在一起



图统计量-以 Twitter 数据集为例

数量



随机 10000 个节点的 Clustering Coefficient 分布
均值为 0.34



随机图的聚类散度

- 对于一个随机图中的节点来说，其平均聚类散度的期望值为：

$$E[C_i] = \frac{2 * E[e_i]}{k_i(k_i - 1)} = \frac{2 * p^{\frac{k_i(k_i - 1)}{2}}}{k_i(k_i - 1)} = p = \frac{\bar{k}}{n - 1}$$

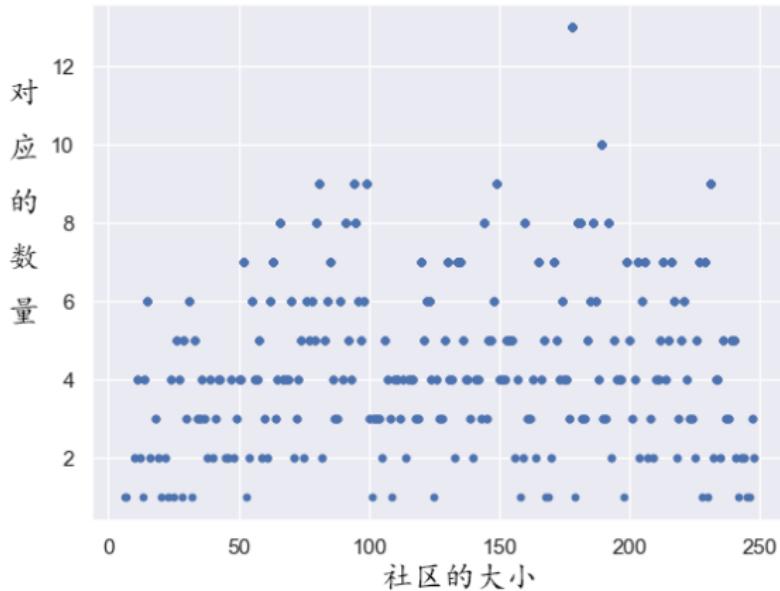
其中 n 为节点数， \bar{k} 是平均度数

- 对 Twitter 数据集而言，同等数量的节点和边构成的随机图，聚类散度的期望是 $\frac{3530653}{157575 * 157575} = 0.0001421$



图统计量-以 Twitter 数据集为例

- 连通区域分布：Twitter 数据集是一个全连通图！

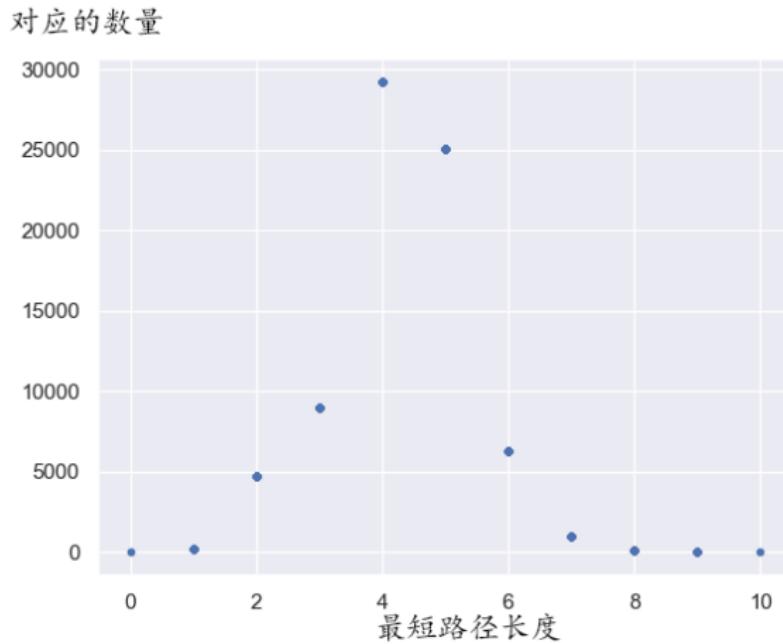


运行社区发现算法，得到的社区大小分布图



图统计量-以 Twitter 数据集为例

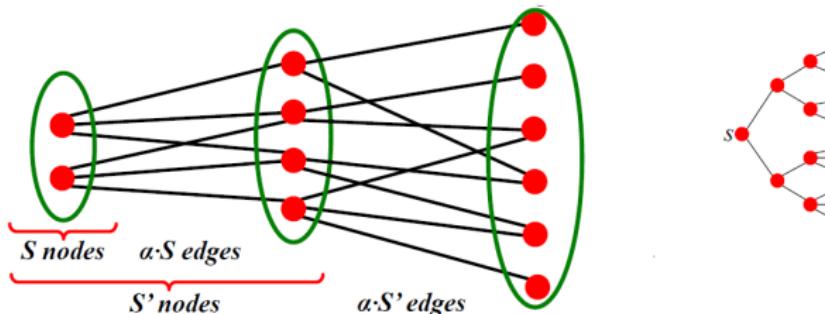
- 计算资源有限，随机 1000 个点的单源最短路径统计分布



随机图的最短路径分布

- 如果图是连通的，那么 BFS 遍历树的第二层应该是初始点的邻接点，然后依次展开直到覆盖图中所有点。假设遍历的是随机图，那么这棵树的深度的期望就应该是

$$\log_{\text{平均的度}} \text{节点总数} = \log_{np} n = \log n / \log np$$



- 对于 Twitter 图来说，平均最短路径的期望为
 $O((\log_{3530653/157575} 157575)) \approx 3.8489422080670335$



1 研究背景

2 基于优化的图结构学习

- LDS
- Pro-GNN

3 基于图结构学习的图神经网络

- AGCN
- GRCN
- PTDNet
- Geom-GCN
- IDGL

4 基于生成模型的图结构学习

5 无监督的图结构学习



基于优化的图结构学习

研究动机

图结构可以看作节点之间是否有边的参数的集合，可以直接对图结构进行参数化学习。

困难与挑战

- ① 优化目标如何确定？
- ② 参数量大 ($O(N^2)$)
- ③ 离散优化，难以训练

Learning Discrete Structures for Graph Neural Networks (LDS)¹

研究动机

真实世界的图结构往往是噪声的或者无法观测的，而好的图结构也将限制基于图数据训练的图神经网络的效果，因此希望将图结构与图神经网络在统一的框架下进行学习。

亮点

- ① 第一个对结构进行学习的工作，打开了后续 GSL 的大门。
- ② 双层优化（Bilevel Programming）影响了很多后续工作

¹Learning Discrete Structures for Graph Neural Networks(ICML 2020)

LDS: Bilevel Programming

$\min_{A, w_A} F(w_A, A)$ such that $w_A \in \arg \min_w L(w, A)$.

$$L(w, A) = \sum_{v \in V_{train}} l(f_w(X, A)_v, y_v) + \Omega(w)$$

$$F(w_A, A) = \sum_{v \in V_{val}} l(f_{w_A}(X, A)_v, y_v)$$

特点: 两个变量 A, w_A 之间并不独立, w_A 是 A 确定情况下优化问题的最小解。

难点: 内层优化 w_A 通常不能得到解析解



LDS: Reparameterization

优化难点

邻接矩阵中的元素是离散变量，无法直接求导

LDS 假设 A 从多个独立的伯努利分布中生成：

$$A \sim \text{Ber}(\theta), \theta \in (0, 1)^{n \times n}$$

优化问题变为：

$$\min_{\theta} \mathbb{E}_{A \sim \text{Ber}(\theta)} [F(w_{\theta}, A)]$$

$$\text{such that } w_{\theta} = \arg \min_w \mathbb{E}_{A \sim \text{Ber}(\theta)} [L(w, A)]$$



LDS：内层优化

$$w_\theta = \arg \min_w \mathbb{E}_{A \sim \text{Ber}(\theta)} [L(w, A)]$$

$$\mathbb{E}_{A \sim \text{Ber}(\theta)} [L(w, A)] = \sum_{A \in \mathcal{H}_N} P_\theta(A) L(w, A)$$

由于采样过程的存在，上式不可能直接求出。

LDS 每次采样一个结构梯度下降：

$$w_{\theta,t+1} = w_{\theta,t} - \gamma \nabla L(w_{\theta,t}, A_t), A_t \sim \text{Ber}(\theta)$$



LDS: 外层优化

$$\min_{\theta} \mathbb{E}_{A \sim \text{Ber}(\theta)} [F(w_{\theta}, A)]$$

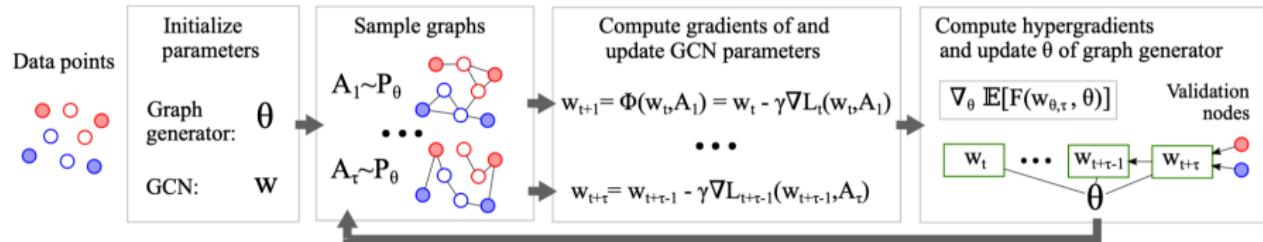
求解对 θ 的梯度，将对期望的梯度近似为梯度的期望：

$$\begin{aligned}\nabla_{\theta} \mathbb{E}_{A \sim \text{Ber}(\theta)} [F(w_{\theta,T}, A)] &\approx \mathbb{E}_{A \sim \text{Ber}(\theta)} [\nabla_A F(w_{\theta,T}, A)] \\ &= \mathbb{E}_A [\partial_w F(w_{\theta,T}, A) \nabla_A w_{\theta,T} + \partial_A F(w_{\theta,T}, A)]\end{aligned}$$

同样使用 SGD 迭代近似最优解：

$$\theta' = \theta - \eta (\partial_w F(w_{\theta,T}, A) \nabla_A w_{\theta,T} + \partial_A F(w_{\theta,T}, A)), A \sim \text{Ber}(\theta)$$

LDS: 交替优化



进行 T 次内层迭代：

$$w_{\theta,t+1} = w_{\theta,t} - \gamma \nabla L(w_{\theta,t}, A_t), A_t \sim \text{Ber}(\theta)$$

进行一次外层迭代：

$$\theta' = \theta - \eta (\partial_w F(w_{\theta,T}, A) \nabla_A w_{\theta,T} + \partial_A F(w_{\theta,T}, A)), A \sim \text{Ber}(\theta)$$

LDS 总结

优点

- ① 系统性提出 Graph Structure Learning 理念
- ② 双层优化方法
- ③ 使用迭代方式优化图结构和 GCN 参数

缺点

- ① 参数量大，优化速度较慢
- ② 边之间相互独立

Graph Structure Learning for Robust Graph Neural Networks(Pro-GNN)

真实图结构的性质 (properties) ²:

- ① 低秩
- ② 稀疏
- ③ 邻接的节点特征相近

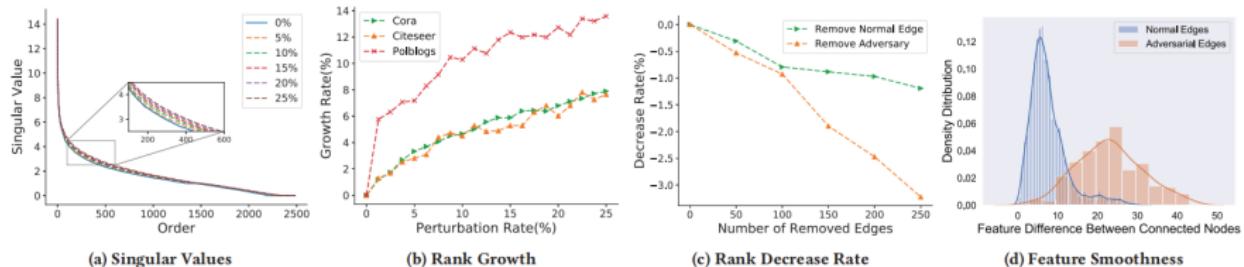


Figure 1: An illustrative example on the property changes of the adjacency matrix by adversarial attacks

²Graph Structure Learning for Robust Graph Neural Networks(KDD 2020)

Pro-GNN: 性质

1. 如何利用这些性质引导图结构的学习?

ProGNN 采取了直接优化邻接矩阵 S 的方法, 将 S 视作一个 $n * n$ 的参数矩阵, 这样这些性质可以表达为有关 S 的一系列损失函数。

图性质的损失函数

① 低秩和稀疏:

$$\mathcal{L}_0 = \|A - S\|_F^2 + \alpha\|S\|_1 + \beta\|S\|_*, s.t., S = S^T$$

② 特征平滑:

$$\mathcal{L}_s = \text{tr}(X^T \hat{L} X) = \frac{1}{2} \sum_{i,j=1}^N S_{ij} \left(\frac{x_i}{\sqrt{d_i}} - \frac{x_j}{\sqrt{d_j}} \right)^2, s.t., S = S^T$$

Pro-GNN: 优化

2. 如何联合学习图结构和图神经网络?

最终损失:

$$\begin{aligned} \arg \min_{S \in \mathcal{S}, \theta} \mathcal{L} &= \mathcal{L}_0 + \lambda \mathcal{L}_f + \gamma \mathcal{L}_{GNN} \\ &= \|A - S\|_F^2 + \alpha \|S\|_1 + \beta \|S\|_* + \gamma \mathcal{L}_{GNN}(\theta, S, X, \mathcal{Y}_L) \\ &\quad + \lambda \text{tr}(X^T \hat{L} X), \text{s.t. } S = S^T \end{aligned}$$

由于一起求解较为困难，使用**交替优化** (Alternative Optimization) 迭代求解。

交替优化

交替优化经常在 GSL 方法中出现，用来解决双层优化等较困难的优化问题。其做法是固定一个，优化另一个，交替进行。

Pro-GNN: 优化

$$\begin{aligned} \arg \min_{S \in \mathcal{S}, \theta} \mathcal{L} = & \|A - S\|_F^2 + \alpha \|S\|_1 + \beta \|S\|_* + \gamma \mathcal{L}_{GNN}(\theta, S, X, \mathcal{Y}_L) \\ & + \lambda \text{tr}(X^T \hat{L} X), \text{s.t. } S = S^T \end{aligned}$$

优化 GNN:

$$\theta \leftarrow \eta' \frac{\partial \mathcal{L}_{GNN}(\theta, S, X, \mathcal{Y}_L)}{\partial \theta}$$

优化图结构 S : 核范数和 l_1 范数不可导, 需使用 Proximal Optimization 数学工具³



³[Jin et al., 2020]

Pro-GNN: 优化

整体算法:

Algorithm 1: Pro-GNN

Data: Adjacency matrix A, Attribute matrix X, Labels \mathcal{Y}_L ,
Hyper-parameters $\alpha, \beta, \gamma, \lambda, \tau$, Learning rate η, η'

Result: Learned adjacency S, GNN parameters θ

- 1 Initialize $S \leftarrow A$
- 2 Randomly initialize θ
- 3 **while** Stopping condition is not met **do**
- 4 $S \leftarrow S - \eta \nabla_S (\|S - A\|_F^2 + \gamma \mathcal{L}_{GNN} + \lambda \mathcal{L}_s)$
- 5 $S \leftarrow \text{prox}_{\eta \beta \|\cdot\|_*}(S)$
- 6 $S \leftarrow \text{prox}_{\eta \alpha \|\cdot\|_1}(S)$
- 7 $S \leftarrow P_S(S)$
- 8 **for** $i=1$ to τ **do**
- 9 $g \leftarrow \frac{\partial \mathcal{L}_{GNN}(\theta, S, X, \mathcal{Y}_L)}{\partial \theta}$
- 10 $\theta \leftarrow \theta - \eta' g$
- 11 **Return** S, θ

每优化 τ 次 GNN 优化一次图结构 S



基于优化的图结构学习

优点

- ① 简单直接
- ② 可解释性强

缺点

- ① 复杂度高
- ② 优化困难
- ③ 无法帮助 GNN

1 研究背景

2 基于优化的图结构学习

- LDS
- Pro-GNN

3 基于图结构学习的图神经网络

- AGCN
- GRCN
- PTDNet
- Geom-GCN
- IDGL

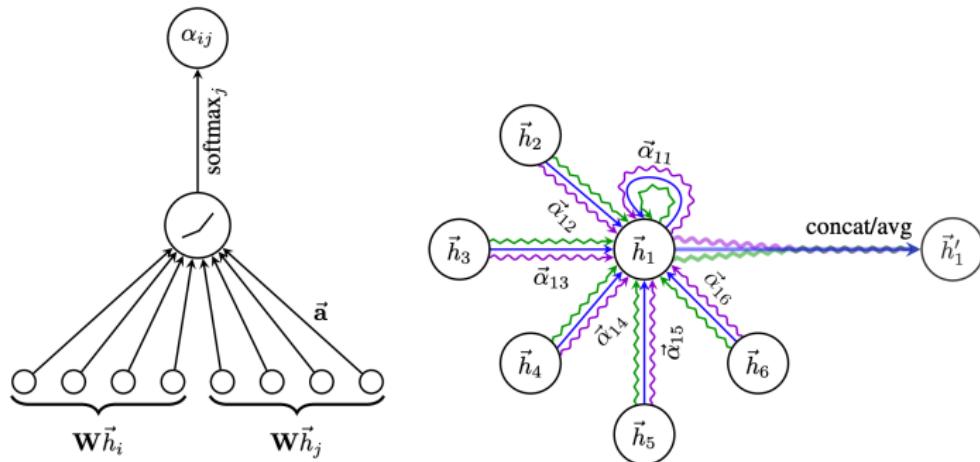
4 基于生成模型的图结构学习

5 无监督的图结构学习



GAT 与图结构学习

$$\alpha_{ij} = \frac{\exp(\text{LeakReLU}(\vec{a}^T [W\vec{h}_i || W\vec{h}_j]))}{\sum_{k \in \mathcal{N}_i} \exp(\text{LeakyReLU}(\vec{a}^T [W\vec{h}_i || W\vec{h}_k]))}$$

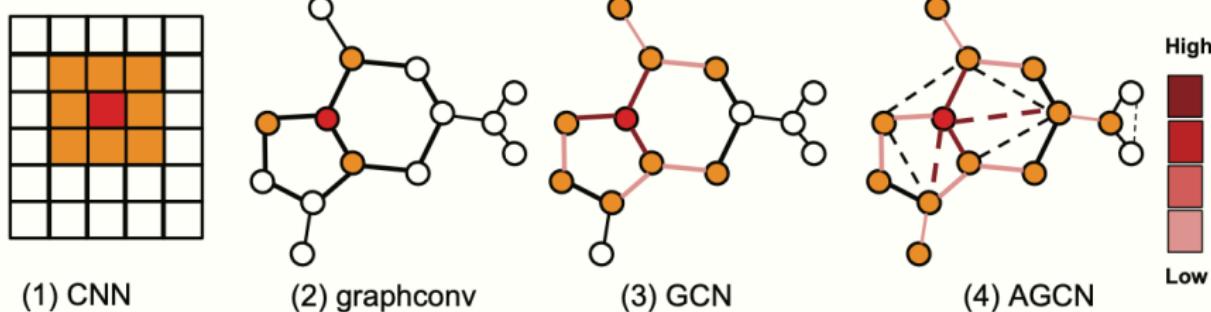


GAT 可看作一种特殊的图结构学习方法。

Adaptive Graph Convolutional Neural Networks (AGCN)

研究动机

现有的图神经网络采用消息传递机制，但仅能在已观测的边上传递信息。由于网络稀疏性问题，实际可传递有效信息的节点并没有被连接。



AGCN 与 CNN、图卷积和 GCN 的对比⁴

Adaptive Graph Convolutional Neural Networks

GCN 模型更新方式：

$$H^{(l+1)} = \sigma \left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)} \right)$$

一个新的图结构即对应一个新的**拉普拉斯矩阵**。

AGCN 对图结构学习的设想

- 图结构可参数化学习
- 参数量少（拉普拉斯矩阵参数化需要 $O(N^2)$ 的空间）
- 可被应用于不同的图结构（可优化更多任务，如点云分类）

解决方案：基于核（kernel）的方法

AGCN 的图结构学习策略

使用广义 Mahalanobis 距离实现基于核的距离度量

$$\mathbb{D}(x_i, x_j) = \sqrt{(x_i - x_j)^T M (x_i - x_j)}$$

- x_i 是图卷积网络某一层中节点 i 的特征。
- $M = W_d W_d^T$, $W_d \in \mathbb{R}^{d \times d}$ 是可学习的 kernel。
- $M = I$ 时等价于欧式距离

将参数量从 $O(N^2)$ 降至 $O(d^2)$!



Adaptive Graph Convolutional Neural Networks

给定距离度量，使用 Gaussian Kernel 归一化得到稠密的邻接矩阵 \tilde{A} 。

$$\tilde{A}_{ij} \leftrightarrow \mathbb{G}_{x_i, x_j} = \exp(-\mathbb{D}(x_i, x_j)/(2\sigma^2))$$

将其作为残差结构与原图结构叠加，得到更新后的拉普拉斯矩阵并用于卷积图神经网络：

$$\hat{L} = L + \alpha L_{res} = L + \alpha(I - \tilde{D}^{-1/2}\tilde{A}\tilde{D}^{-1/2})$$

为什么要加上原来的图结构？



Adaptive Graph Convolutional Neural Networks

总结与归纳：

优点

- ① 模型简单，启发了很多后续的图结构学习工作
- ② 参数量小，便于优化

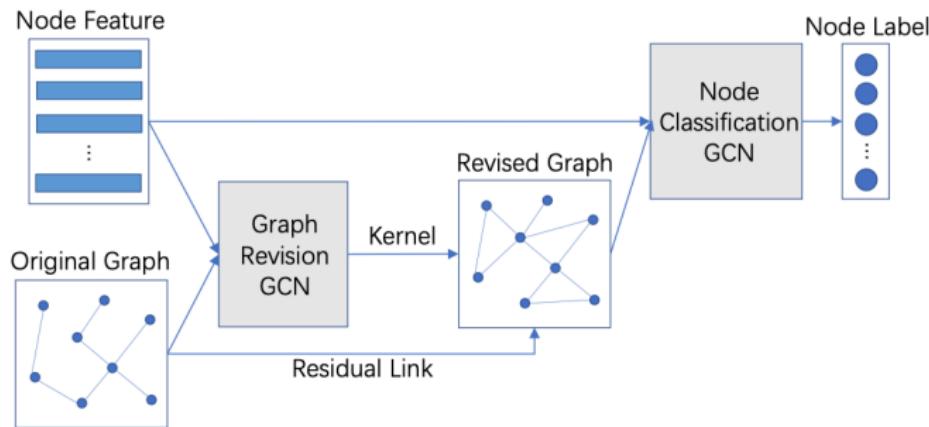
缺点

- ① 结构仅通过线性变换学习
- ② 学习的拉普拉斯矩阵过于稠密
- ③ 图神经网络没有给结构学习带来信息
- ④ 模型缺乏明确的结构学习优化目标

Graph-Revised Convolutional Network(GRCN)

研究动机

图结构学习不应只增加边，稀疏性是图数据的天然特性。



GRCN 模型⁵

⁵ Graph-Revised Convolutional Network(ECML-PKDD 2020)

GRCN:Graph-Revised GCN

Graph-Revised GCN 模块

利用原始的节点特征和图结构，学习节点之间基于表征 z_i, z_j 的邻近性 S_{ij} 进而更新图结构 \tilde{A} 。

$$Z = GCN_g(A, X)$$

$$S_{ij} = k(z_i, z_j)$$

$$\tilde{A} = A + S$$

相比于 AGCN，这里使用了更为“暴力”的相似度学习方式。

GRCN: 图稀疏化

Graph Sparsification 模块

直接将稠密相似度矩阵 S 与原始邻接矩阵 A 相加，会导致邻接矩阵非常稠密，因此使用 KNN 进行稀疏化。

$$S_{ij}^{(K)} = \begin{cases} S_{ij}, & S_{ij} \in \text{top } K(S_i) \\ 0, & S_{ij} \notin \text{top } K(S_i). \end{cases}$$

为了保持邻接矩阵的对称性，做对称性变换

$$\hat{S}_{ij} = \begin{cases} \max\left(S_{ij}^{(K)}, S_{ji}^{(K)}\right), & S_{ij}^{(K)}, S_{ji}^{(K)} \geq 0 \\ \min\left(S_{ij}^{(K)}, S_{ji}^{(K)}\right), & S_{ij}^{(K)}, S_{ji}^{(K)} \leq 0 \end{cases}$$



GRCN：模型训练

将更新之后的图结构与原始特征一起训练 Node Classification GCN 模块：

$$\hat{Y} = GCN_c(\tilde{A}, X)$$

$$\zeta = - \sum_{i \in \mathcal{Y}_L} \sum_{j=1}^C Y_{ij} \ln \hat{Y}_{ij}$$

整个过程完全使用神经网络进行学习和优化。



GRCN：实验效果

Models	Cora-Full	Amazon Computers	Coauthor CS
GCN	60.3 ± 0.7	81.9 ± 1.7	91.3 ± 0.3
SGC	59.1 ± 0.7	81.8 ± 2.3	91.3 ± 0.2
GAT	59.9 ± 0.6	81.8 ± 2.0	89.5 ± 0.5
LDS	N/A	N/A	N/A
GLCN	59.1 ± 0.7	80.4 ± 1.9	90.1 ± 0.5
Fast-GRCN	60.2 ± 0.5*	83.5 ± 1.6*	91.2 ± 0.4*
GRCN	60.3 ± 0.4	83.7 ± 1.8	91.3 ± 0.3

思考

GRCN 在什么情况下可以取得效果的提升？

Learning to Drop: Robust Graph Neural Network via Topological Denoising

研究动机

网络中观察到的边往往存在与任务无关的边，通过这些节点传递信息往往给节点表征学习带来噪声。

		Ratio of positive edges removed										
		0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1
Ratio of negative edges removed	0	60.1	60.1	55.7	55.2	54.8	54.8	54.2	53.8	53.6	53.5	53.5
	0.1	64.2	63.7	61.4	60.0	59.6	59.4	59.3	58.7	58.7	58.6	57.4
	0.2	69.6	68.2	66.5	66.4	66.1	65.4	63.6	63.8	62.6	62.1	61.2
	0.3	72.8	72.3	71.5	70.5	70.2	69.0	68.3	67.7	68.9	67.6	66.8
	0.4	79.3	76.9	74.5	73.5	73.5	72.9	72.6	71.8	71.2	70.3	69.5
	0.5	80.4	79.2	78.0	76.6	75.6	75.3	75.1	74.3	73.7	73.6	72.3
	0.6	83.6	82.4	81.3	80.6	80.3	78.6	78.1	77.3	76.8	75.0	74.1
	0.7	83.9	82.6	81.6	81.5	81.0	80.1	79.5	78.2	78.1	77.7	76.5
	0.8	85.5	83.8	83.5	82.8	81.1	80.7	80.7	79.9	79.6	79.9	79.4
	0.9	86.3	86.1	84.8	83.6	83.6	82.6	82.4	81.8	81.3	81.1	81.0
	1	87.2	86.2	85.3	85.1	84.3	84.1	84.0	83.0	82.1	82.1	81.1

PTDNet: 图的稀疏化

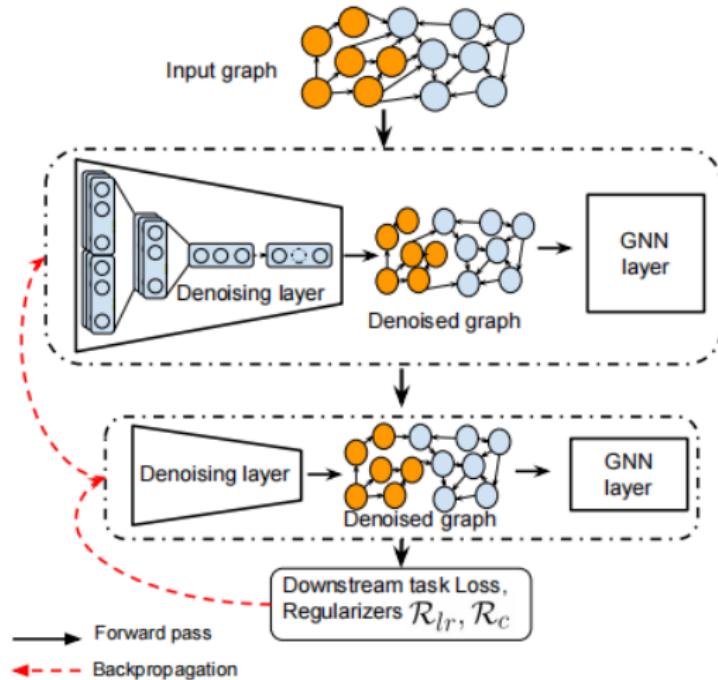
Dropout 的思想被用于神经网络用以加强模型鲁棒性，
PTDNet⁶希望通过删除部分边来提升图神经网络的鲁棒性。

图的稀疏化和图结构学习

- ① 图的稀疏化可以视作一种图结构学习，但仅在初始存在的边上进行，即可以去除冗余的边，但不能增加新边（后者往往需要耗费更多空间）。
- ② 该不同之处通常表现在得到新的结构后与原结构乘还是加。

⁶Learning to Drop: Robust Graph Neural Network via Topological Denoising(WSDM 2021)

PTDNet: 降噪网络



将节点间边的概率基于节点的表征，并用神经网络进行学习。

PTDNet: 降噪网络

- ① 每层 GCN 均配备一个降噪网络，使用上一层表征: $\alpha_{ij}^l = MLP^l(\vec{h}_i^l, \vec{h}_j^l)$
- ② 重采样，使概率模型可导：
$$\beta_{ij}^l = sigmoid((\log \epsilon - \log(1 - \epsilon) + \alpha_{ij}^l)/\tau), \epsilon \sim Uniform(0, 1)$$
- ③ 将其映射至 0-1 之间: $Z_{ij}^l = P_S(\beta_{ij}^l)$
- ④ 与原结构相乘（这里决定了无法添加新边）： $S^l = A \odot Z^l$
- ⑤ 卷积： $H^{l+1} = GCN^l(S^l, X)$

PTDNet: 实验效果

Backbone	Method	Cora	Citeseer	Pubmed	PPI
GCN	Basic	0.811 ± 0.015	0.703 ± 0.012	0.790 ± 0.020	0.660 ± 0.024
	DropEdge	0.809 ± 0.035	0.722 ± 0.032	0.785 ± 0.043	0.606 ± 0.041
	NeuralSparse	0.821 ± 0.014	0.715 ± 0.014	0.788 ± 0.018	0.651 ± 0.014
	PTDNet-wl	0.824 ± 0.018	0.717 ± 0.170	0.791 ± 0.012	0.752 ± 0.017
	PTDNet	0.828 ± 0.026	0.727 ± 0.018	0.798 ± 0.024	0.803 ± 0.008
GraphSage	Basic	0.792 ± 0.027	0.676 ± 0.023	0.767 ± 0.020	0.618 ± 0.014
	DropEdge	0.787 ± 0.023	0.670 ± 0.031	0.748 ± 0.026	0.610 ± 0.035
	NeuralSparse	0.793 ± 0.021	0.674 ± 0.011	0.751 ± 0.021	0.626 ± 0.023
	PTDNet-wl	0.794 ± 0.026	0.678 ± 0.022	0.770 ± 0.024	0.645 ± 0.020
	PTDNet	0.803 ± 0.019	0.679 ± 0.018	0.771 ± 0.010	0.648 ± 0.025
GAT	Basic	0.830 ± 0.007	0.721 ± 0.009	0.790 ± 0.008	0.973 ± 0.012
	DropEdge	0.832 ± 0.040	0.709 ± 0.020	0.779 ± 0.019	0.850 ± 0.038
	NeuralSparse	0.834 ± 0.015	0.724 ± 0.026	0.780 ± 0.017	0.921 ± 0.018
	PTDNet-wl	0.837 ± 0.022	0.723 ± 0.014	0.792 ± 0.014	0.978 ± 0.018
	PTDNet	0.844 ± 0.023	0.737 ± 0.031	0.793 ± 0.015	0.980 ± 0.022

Geometric Graph Convolutional Networks(Geom-GCN)

研究动机

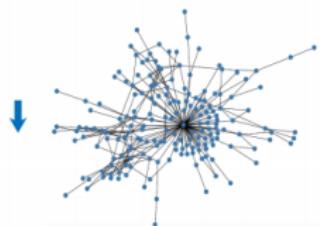
- 现有的基于消息传递机制的 GNN，容易损失长距离、全局结构信息，在同质性低（相邻节点倾向于不同类别）的图上表现不佳。
- 简单堆叠深层 GNN 产生过度平滑问题，一个簇中的节点表征经过多层消息传播趋同。

Geom-GCN⁷的解决思路：通过结构学习使得需要传递消息的节点对成为邻居。

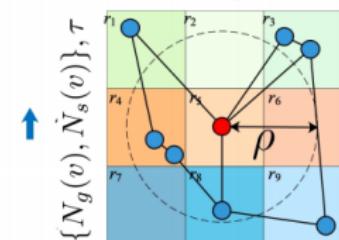
⁷ Geometric Graph Convolutional Networks(ICLR 2020)

Geom-GCN

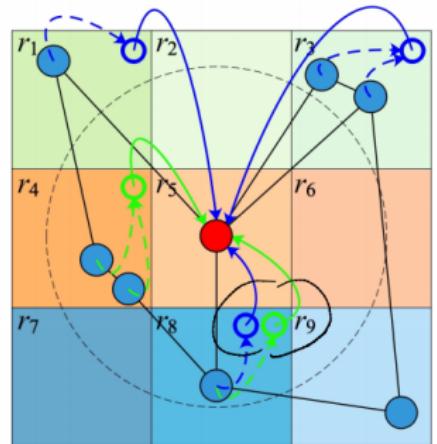
A1 Original graph



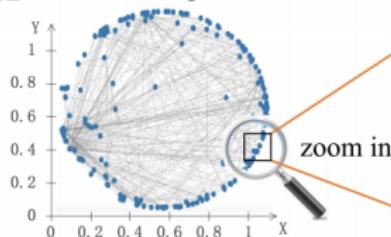
B2 Structural neighborhood



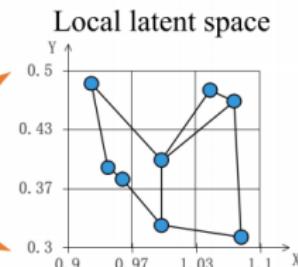
C Bi-level aggregation



A2 Latent space



B1 Local latent space



→ Low level aggregation

→ High level aggregation

○ Virtual nodes

- 使用图嵌入方法，获得节点的隐空间表征。
- 根据这些表征，在图中构建新边。
- 为区分边的类型，改动 GCN 的消息传播方式

实现步骤:

- ① 使用 embedding method 获得图中节点隐空间表征: $e_v = f(v)$
- ② 定义规则从隐空间中产生新边:
 $N_s(v) = \{u | u \in V, d(e_u, e_v) < \rho\}$, 即在隐空间中相近的节点间构建新边。
- ③ 定义边的类型: $r = \tau(e_u, e_v), u \in N_g(v) \cup N_s(v)$
(论文中隐空间表征 2 维, 将其按位置关系简单分为 4 类, 考虑边的来源总共为 8 类)

$\tau(z_v, z_u)$	$z_v[0] > z_u[0]$	$z_v[0] \leq z_u[0]$
$z_v[1] \leq z_u[1]$	upper left	upper right
$z_v[1] > z_u[1]$	lower left	lower right

边类型的产生

Geom-GCN

实现步骤:

- ① 使用 embedding method 获得图中节点隐空间表征: $e_v = f(v)$
- ② 定义规则从隐空间中产生新边:
 $N_s(v) = \{u | u \in V, d(e_u, e_v) < \rho\}$, 即在隐空间中相近的节点间构建新边。
- ③ 定义边的类型: $r = \tau(e_u, e_v), u \in N_g(v) \cup N_s(v)$
- ④ 不同类型的边分别进行传播, 之后再聚合

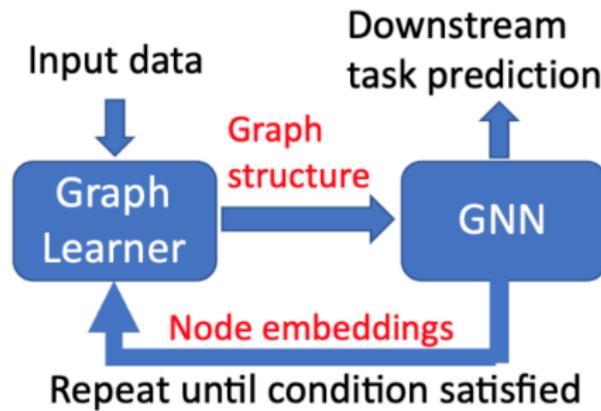
$$\boldsymbol{e}_{(i,r)}^{v,l+1} = \sum_{u \in N_i(v)} \delta(\tau(\boldsymbol{z}_v, \boldsymbol{z}_u), r) (\deg(v) \deg(u))^{\frac{1}{2}} \boldsymbol{h}_u^l$$

$$\boldsymbol{h}_v^{l+1} = \sigma \left(\boldsymbol{W}_l \cdot \prod_{i \in \{g,s\}} \|_{r \in R} \boldsymbol{e}_{(i,r)}^{v,l+1} \right)$$

Iterative Deep Graph Learning for Graph Neural Networks: Better and Robust Node Embeddings

研究动机

图结构与图神经网络学习可以相互帮助：好的图结构可以学习好的图神经网络，好的图神经网络结果可以帮助建模更准确的网络结构。



从图结构学习到图神经网络

- 图结构沿用 AGCN 的思想：融合原始网络结构与学习过程中的网络结构

$$\tilde{\mathbf{A}}^{(t)} = \lambda \mathbf{L}^{(0)} + (1 - \lambda) \left\{ \eta \mathbf{f}(\mathbf{A}^{(t)}) + (1 - \eta) \mathbf{f}(\mathbf{A}^{(1)}) \right\}$$

- 图神经网络沿用经典的 GCN：

$$\mathbf{Z} = \text{ReLU} \left(\mathbf{MP}(\mathbf{X}, \tilde{\mathbf{A}}) \mathbf{W}_1 \right), \hat{\mathbf{y}} = \sigma \left(\mathbf{MP}(\mathbf{Z}, \tilde{\mathbf{A}}) \mathbf{W}_2 \right)$$

$$\mathcal{L}_{\text{pred}} = \ell(\hat{\mathbf{y}}, \mathbf{y})$$



根据图神经网络学习图结构

基本假设

具有相似的低维表征的节点对，有更大的概率生成边。

基于节点表征的边概率计算：

- 第一层：基于向量的相似度计算

$$S_{ij} = \cos(\vec{w}_p \odot \vec{z}_i, \vec{w}_p \odot \vec{z}_j)$$

- 第二层：基于多头向量的相似度计算

$$S_{ij} = \frac{1}{m} \sum_{p=1}^m \cos(\vec{w}_p \odot \vec{z}_i, \vec{w}_p \odot \vec{z}_j)$$



根据图神经网络学习图结构

使用节点表征相似度预测图结构的缺陷：

- ① 计算复杂度高
- ② 网络过于稠密

IDGL 的解决方案：

- 第三层：Anchor-based 度量学习：

$$a_{ik}^p = \cos(\mathbf{w}_p \odot \mathbf{v}_i, \mathbf{w}_p \odot \mathbf{u}_k), \quad a_{ik} = \frac{1}{m} \sum_{p=1}^m a_{ik}^p$$

- 第四层：图稀疏化。只选择每个节点最近的 K 个节点，或相似度大于阈值 ϵ 的邻居节点。

图结构质量控制

IDGL 迭代优化的缺陷

图结构学习模块缺少监督信号，容易陷入局部平凡解 (Trival Solution)

好的图结构应具有如下性质：

- ① 平滑性：临近的节点的属性相似度应该逐渐下降

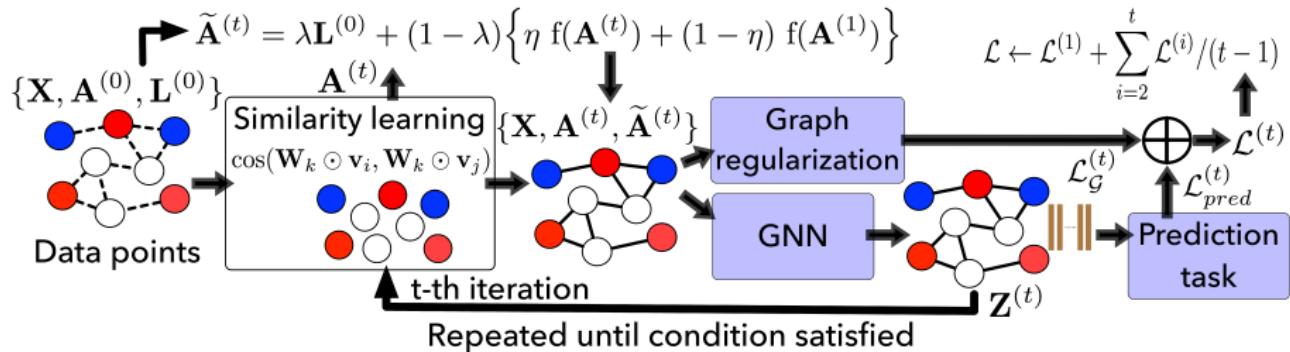
$$\Omega(\mathbf{A}, \mathbf{X}) = \frac{1}{2n^2} \sum_{i,j} A_{ij} \|\mathbf{x}_i - \mathbf{x}_j\|^2 = \frac{1}{n^2} \text{tr} (\mathbf{X}^T \mathbf{L} \mathbf{X})$$

- ② 连通性：网络中的节点尽可能构成联通图
- ③ 稀疏性：网络中的边总体稀疏

$$f(\mathbf{A}) = \frac{-\beta}{n} \mathbf{1}^T \log(\mathbf{A}\mathbf{1}) + \frac{\gamma}{n^2} \|\mathbf{A}\|_F^2$$



IDGL 模型



IDGL 方法示意图

优点

- ① 提出了统一的迭代学习框架
- ② 明确了结构学习的优化目标
- ③ 使用多种手段兼顾效率与精度

循环优化图神经网络

一般形式：

- ① 使用已有结构学习节点表征 z

$$\mathbf{z} = GNN(X, A)$$

- ② 利用节点表征相似度学习图结构：

$$\tilde{\mathbf{A}}_{ij} = \phi(\mathbf{z}_i, \mathbf{z}_j)$$

- ③ 融合输入结构和学习图结构

$$\mathbf{A}^* = g(\mathbf{A}, \tilde{\mathbf{A}})$$

迭代循环，直至收敛。



基于节点相似度的图结构生成

① Gaussian Kernel

$$\begin{aligned}\phi(\mathbf{z}_i, \mathbf{z}_j) &= \sqrt{(\mathbf{z}_i - \mathbf{z}_j)^\top \mathbf{M} (\mathbf{z}_i - \mathbf{z}_j)} \\ \tilde{\mathbf{A}}_{ij} &= \exp\left(-\frac{\phi(\mathbf{z}_i, \mathbf{z}_j)}{2\sigma^2}\right)\end{aligned}$$

② 向量内积

$$\tilde{\mathbf{A}} = \sigma(\mathbf{Z}\mathbf{Z}^\top)$$

③ Cosine 相似度

$$\phi(\mathbf{z}_i, \mathbf{z}_j) = \frac{\mathbf{z}_i \mathbf{z}_j^\top}{\|\mathbf{z}_i\|_2 \|\mathbf{z}_j\|_2}.$$



1 研究背景

2 基于优化的图结构学习

- LDS
- Pro-GNN

3 基于图结构学习的图神经网络

- AGCN
- GRCN
- PTDNet
- Geom-GCN
- IDGL

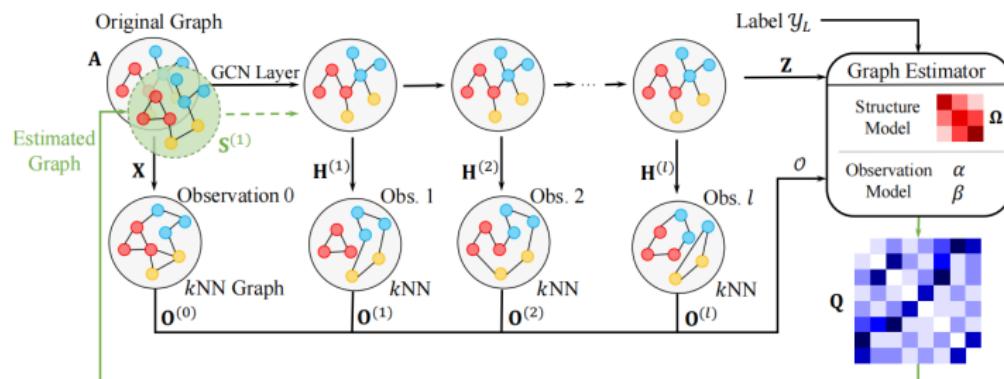
4 基于生成模型的图结构学习

5 无监督的图结构学习



Graph Structure Estimation Neural Networks

GEN 是一种概率建模 GSL 方法，相比之前这一类方法考虑图结构的内在产生过程，往往对这一过程参数化，并使用合适的优化方法与节点分类任务结合。



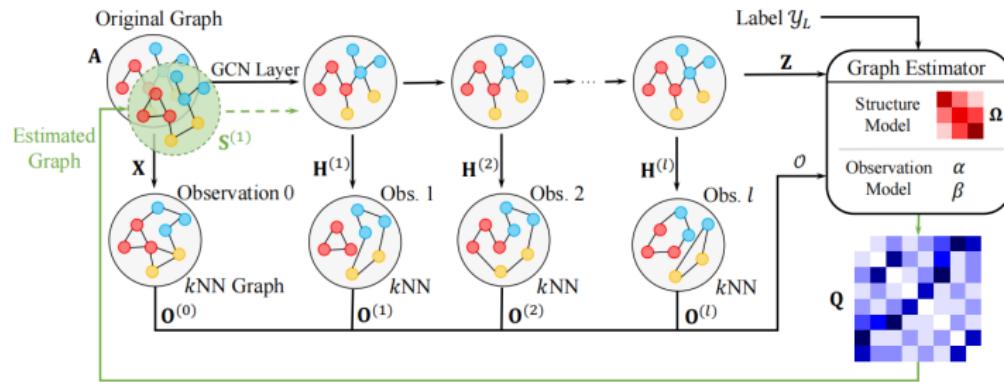
GEN 的模型示意图



Graph Structure Estimation Neural Networks

研究动机

现有的图结构学习方法仅考虑图数据的判别特性（节点之间是否有边），对网络的生成过程缺乏可解释性。



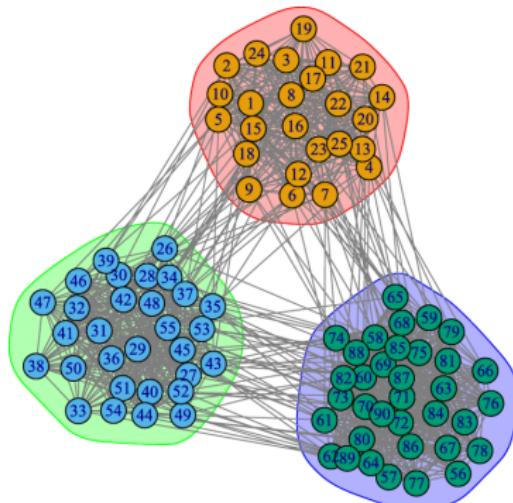
GEN 的模型示意图⁸

⁸[Wang et al., 2021]

SBM 模型简介

Stochastic Block Model(SBM)

Stochastic Block Model(SBM) 是一种经典的网络生成模型。它假设网络中边的生成是由两个节点的社区分布决定，即属于同一个社区的节点有更大的概率生成边，不同社区的节点生成边的概率更小。



GEN 的图结构建模

在 SBM 模型的假设下，网络中存在边的概率只与两个节点所属的社区有关。给定参数矩阵 $\Omega \in \mathcal{S}^{|C|*|C|}$ ，观测到网络的概率为：

$$P(G|\Omega, Z, \mathcal{Y}_L) = \prod_{i < j} \Omega_{c_i c_j}^{G_{ij}} (1 - \Omega_{c_i c_j})^{1-G_{ij}}$$

c_i 表示节点 i 的类别。当其属于训练集时，使用真实标签；当属于无标签节点时，使用预测标签。

$$c_i = \begin{cases} y_i & \text{if } v_i \in \mathcal{V}_L \\ z_i & \text{otherwise} \end{cases}$$



GEN 的图结构建模

模型假设

给定最优的图结构 G , 真实观测的图结构由最优图结构随机采样后生成。

定义最优图结构下有边和没有边, 在观测图结构下存在边的概率为 α , β , 观测图结构的概率为:

$$P(O \mid G, \alpha, \beta) = \prod_{i < j} [\alpha^{E_{ij}} (1 - \alpha)^{M - E_{ij}}]^{G_{ij}} \times [\beta^{E_{ij}} (1 - \beta)^{M - E_{ij}}]^{1 - G_{ij}}$$

其中 E_{ij} 为给定的一组 M 个观测图结构中 ij 之间出现边的次数,

GEN 的模型优化

GEN 模型需要优化的参数有最优图结构 G 和图神经网络参数 Θ 。然而参数优化存在两大类困难：

- ① 两种参数高度耦合（迭代求解）
- ② 最优图结构 Q 为离散变量（转化为伯努利分布参数）

优化 GNN:

$$\theta \leftarrow \eta' \frac{\partial \mathcal{L}_{GNN}(\theta, S, X, \mathcal{Y}_L)}{\partial \theta}$$

优化图结构 S :

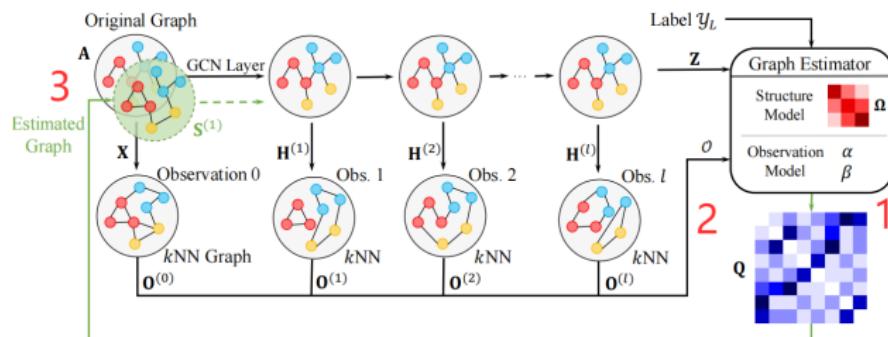
$$S \leftarrow EM(O^{(0)}, O^{(1)}, O^{(2)}, \dots, O^{(l)}, O^{(l+1)})$$

式中 $O^{(i)}$ 为不同阶段的表征产生的 KNN 图。



GEN 的基本思路:

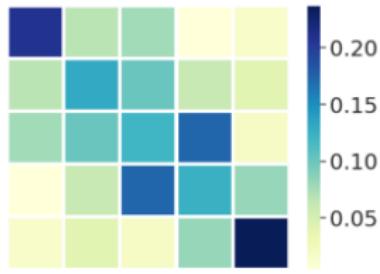
- ① 假设存在一个图的**最优结构**, 从一个**SBM 模型**中生成。
- ② 假设该最优结构存在多个**观测**, 从节点不同阶段的表示中各**自生成 KNN 图**作为观测。
- ③ **交替优化**, 在训练好的 GCN 基础上使用**EM 算法**求解最优结构, 将其作为新的结构重新训练。



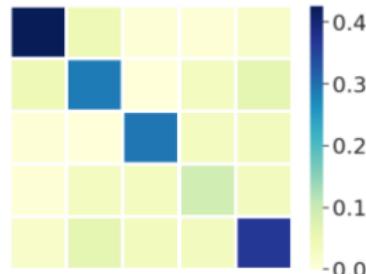
GEN 的模型示意图

GEN: 同质性

在 toy dataset 上验证了: GEN 可以增加相同类别节点之间的边,减少连接不同类别的边。
体现了 GEN 可以学习具有同质性的图结构的能力。



(a) Original graph



(b) Estimated graph

GEN 产生结构的同质性



1 研究背景

2 基于优化的图结构学习

- LDS
- Pro-GNN

3 基于图结构学习的图神经网络

- AGCN
- GRCN
- PTDNet
- Geom-GCN
- IDGL

4 基于生成模型的图结构学习

5 无监督的图结构学习



Unsupervised GSL

以上的方法都基于有监督情况，结构学习依赖监督信息

Drawbacks

- ① 不平衡。标签有限时有标签节点周围边受到监督信息引导，但距离有标签节点距离远的边难以学习。
- ② 不实用。相较于监督情况，无监督情况更广泛。
- ③ 不通用。对于每个任务都要重新学习结构，不能学习一个通用的结构。

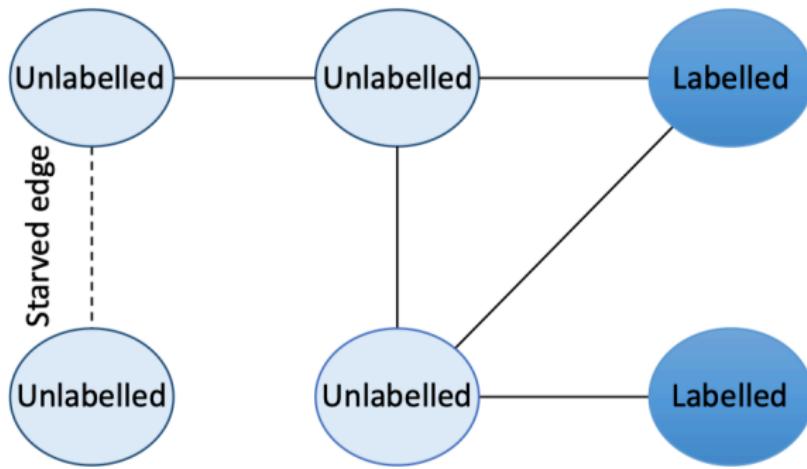
近期出现的 Unsupervised GSL 工作大多利用了对比学习的思想，关键在于如何设计不同的 view，如何融入结构学习。

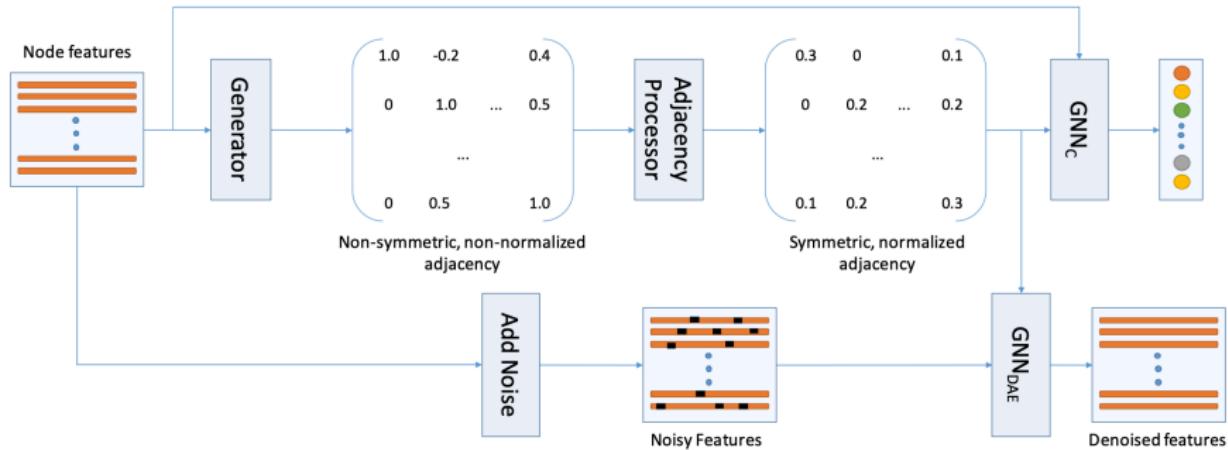


SLAPS: Self-Supervision Improves Structure Learning for Graph Neural Networks

研究动机

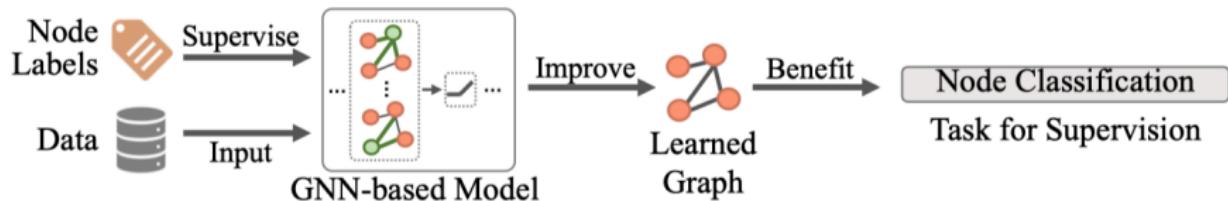
传统的 GSL 方法，虽然使用了半监督模型帮助引导结构学习，但是并不是所有节点都会被惠及。



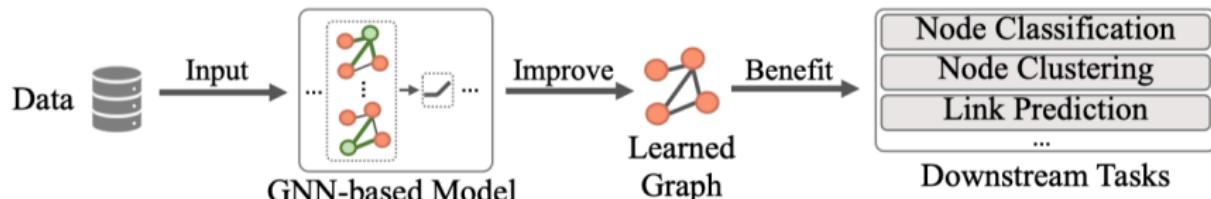


SLAPS 解决方案：引入 DAE 作为自监督信号

Towards Unsupervised Deep Graph Structure Learning

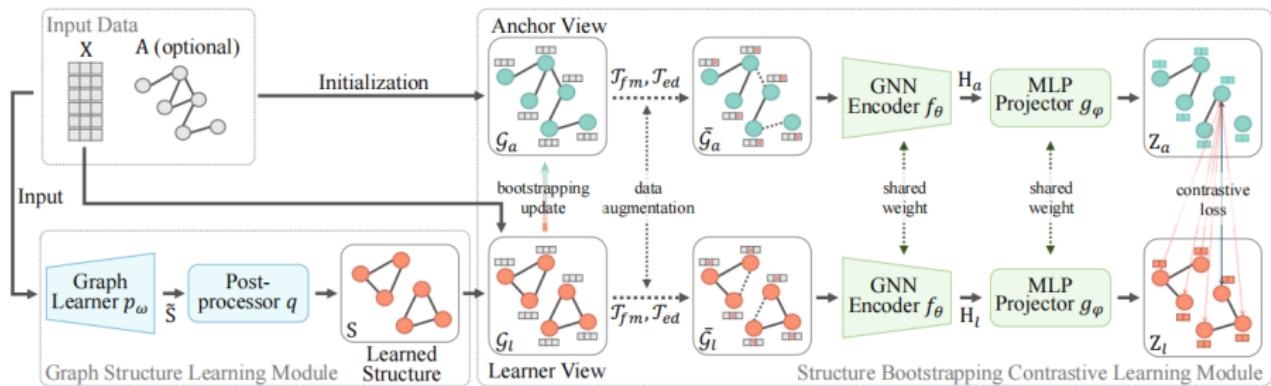


有监督 GSL



无监督 GSL⁹

Towards Unsupervised Deep Graph Structure Learning



可学习的 GSL 模块产生 learner view，原结构作为 anchor view，最大化两个 view 之间的互信息（MI）

SUBLIME: Graph Learner

Graph Learner

Graph Learner 用于学习图结构，本文讨论了多种传统的方法：

- ① 直接优化
- ② Metric Learning

1. 直接将整个图作为参数：

$$S = g(\Omega), \Omega \in R^{n \times n}$$

2. Learnable encoder+metric：

$$S = metric(encoder_w(X, A))$$

再经过后处理操作（对称化、稀疏化等）得到 learner view
 $G_l = (S, X)$



SUBLIME: Graph Learner

Metric Learning based Graph Learner 的几种实现方式:

- ① Attentive Learner:

$$\mathbf{E}^{(l)} = h_w^{(l)}(\mathbf{E}^{(l-1)}) = \sigma \left(\left[\mathbf{e}_1^{(l-1)} \odot \omega^{(l)}, \dots, \mathbf{e}_n^{(l-1)} \odot \omega^{(l)} \right]^\top \right)$$

- ② MLP Learner:

$$\mathbf{E}^{(l)} = h_w^{(l)}(\mathbf{E}^{(l-1)}) = \sigma(\mathbf{E}^{(l-1)} \Omega^{(l)})$$

- ③ GNN Learner

$$\mathbf{E}^{(l)} = h_w^{(l)}(\mathbf{E}^{(l-1)}, \mathbf{A}) = \sigma \left(\widetilde{\mathbf{D}}^{-\frac{1}{2}} \widetilde{\mathbf{A}} \widetilde{\mathbf{D}}^{-\frac{1}{2}} \mathbf{E}^{(l-1)} \right)$$

SUBLIME: Post-processor

Post-processor

Post-processor 用于处理 Graph Learner 学到的结果，以便于下游应用和训练。

图结构稀疏化 Sparsification:

$$\tilde{s}_{ij}^{(sp)} = q_{sp} \left(\tilde{\mathbf{S}}_{ij} \right) = \begin{cases} \tilde{s}_{ij}, & \tilde{\mathbf{S}}_{ij} \in \text{top-k} \left(\tilde{\mathbf{S}}_i \right), \\ 0, & \tilde{\mathbf{S}}_{ij} \notin \text{top-k} \left(\tilde{\mathbf{S}}_i \right), \end{cases}$$

图归一化:

$$\tilde{\mathbf{S}}^{(sym)} = q_{\text{sym}} \left(q_{\text{act}} \left(\tilde{\mathbf{S}}^{(sp)} \right) \right) = \frac{\sigma_q \left(\tilde{\mathbf{S}}^{(sp)} \right) + \sigma_q \left(\tilde{\mathbf{S}}^{(sp)} \right)}{2}$$



Contrastive Learning

得到 learner view $G_l(A, S)$ 后和预先指定的 anchor view (文中设置为原图 $G_a = (A, X)$) 进行对比学习。

使用共享的 GCN+MLP 得到表征：

$$Z_l = g_\phi(f_\theta(\overline{G}_l)), Z_a = g_\phi(f_\theta(\overline{G}_a))$$

对比学习最大化互信息：

$$\mathcal{L} = \frac{1}{2n} \sum_{i=1}^n [\ell(z_{l,i}, z_{a,i}) + \ell(z_{a,i}, z_{l,i})]$$
$$\ell(z_{l,i}, z_{a,i}) = \log \frac{e^{\text{sim}(z_{l,i}, z_{a,i})/t}}{\sum_{k=1}^n e^{\text{sim}(z_{l,i}, z_{a,k})/t}}$$



更新 Anchor view

一直使用原图作为 anchor view 会带来原结构中的误差，文中每隔若干轮次更新，和当前学习的结构加权：

$$A_a = \tau A_a + (1 - \tau)S$$



Reliable Representations Make A Stronger Defender: Unsupervised Structure Refinement for Robust GNN(STABLE)

研究动机

聚焦基于距离度量的 GSL 方法，认为监督情况下得到的表征容易受扰动，本身质量不佳，不能产生好的结构。

STABLE¹⁰解决方案：

- ① 使用对比学习得到更可靠的表征
- ② 利用更可靠的表征更新图结构



¹⁰ Reliable Representations Make A Stronger Defender: Unsupervised Structure Refinement for Robust GNN(KDD 2022)

基本假设

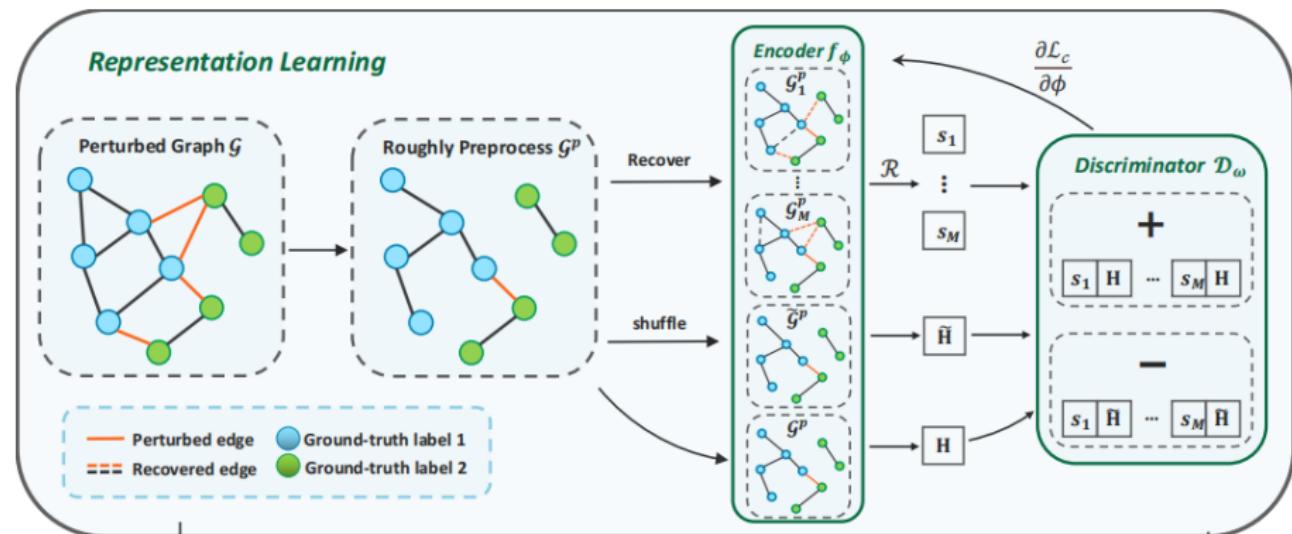
实际对抗攻击过程，往往是增加边而不是删除边。

对于一个含噪声的图 G :

- ① 删除一部分边，得到噪声程度低的图 G^p
- ② 从 G^p 中随机恢复被删除的边，构成 M 个噪声程度较高的图 $G_1^p, G_2^p, \dots, G_M^p$
- ③ 要求从 G^p 和 $G_1^p, G_2^p, \dots, G_M^p$ 得到的表征接近，同时 shuffle G^p 得到 \tilde{G}^p 作为负样本，要求 \tilde{G}^p 和 $G_1^p, G_2^p, \dots, G_M^p$ 得到的表征接近

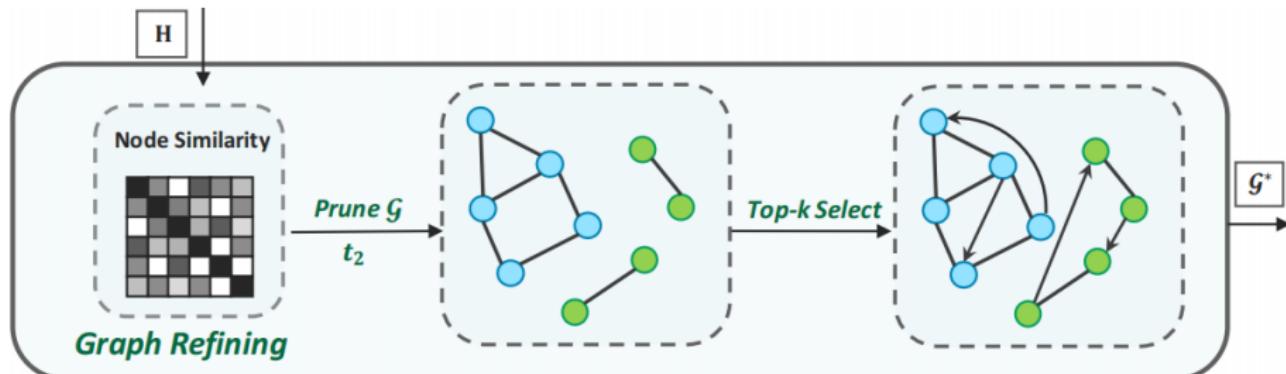


STABLE: Representation Learning



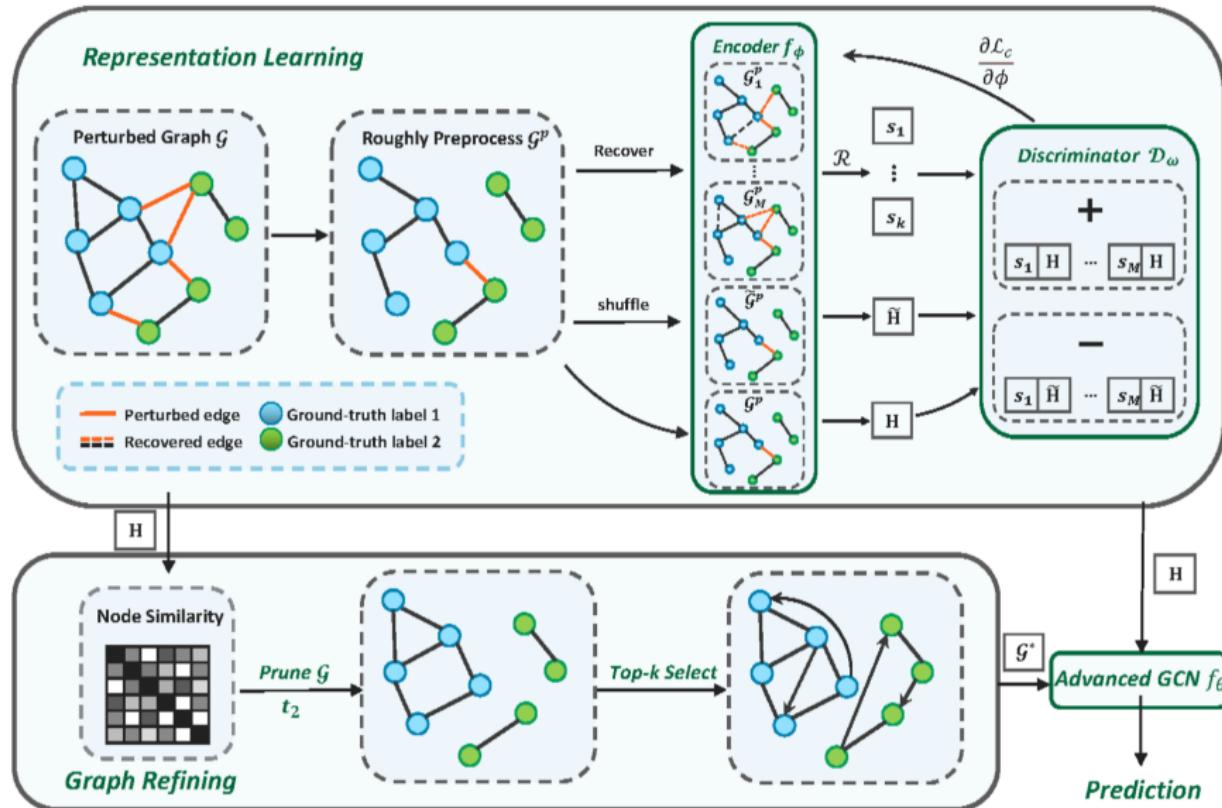
STABLE: Graph Refining

在获得 reliable 的表征 H 后，使用常规的相似度计算和后处理得到最终的结构：



该结构与任务无关的，从无监督方法获得，可以直接用于多个下游任务。

STABLE



未来展望

当前图结构学习的问题：

- ① 图结构学习，只假设网络结构有问题，没有关注网络中节点属性的问题
- ② 半监督信号能否指导全局节点的结构学习
- ③ 如何避免模型训练过程中的 error propagation
- ④ ...

图结构学习的端到端应用：

- ① 图异常检测
- ② 社区发现
- ③ 图对抗攻防
- ④ ...



课程总结

- ① 研究背景
- ② 基于优化的图结构学习
 - LDS
 - Pro-GNN
- ③ 基于图结构学习的图神经网络
 - AGCN
 - GRCN
 - PTDNet
 - Geom-GCN
 - IDGL
- ④ 基于生成模型的图结构学习
- ⑤ 无监督的图结构学习



References I

-  Jin, W., Ma, Y., Liu, X., Tang, X., Wang, S., and Tang, J. (2020). Graph structure learning for robust graph neural networks. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 66–74.
-  Wang, R., Mou, S., Wang, X., Xiao, W., Ju, Q., Shi, C., and Xie, X. (2021). Graph structure estimation neural networks. In *Proceedings of the Web Conference 2021*, pages 342–353.

